The background features a decorative graphic consisting of three blue circles of varying sizes, each composed of concentric rings. Two thin blue lines intersect diagonally, forming an 'X' shape that passes behind the circles.

Diseño del analizador léxico, del gestor de errores y de la tabla de símbolos.

Contenido

Componentes del grupo.....	3
Identificación de tokens	4
Gramática del analizador léxico	5
Notación “habitual”	5
Notación EBNF.....	6
Autómata finito	9
Números.....	9
Operadores.....	10
Resto.....	12
Acciones semánticas	13
Reconocimiento de números	13
Reconocimiento de operadores.....	14
Tabla de transiciones del autómata	17
Tabla de símbolos.....	21
Gestión de palabras reservadas.	21
Gestión de ámbitos.	21
Gestión de los errores.....	22
Funcionamiento básico	22
Tipos	22
Interfaz	22
Tabla de errores léxicos	23

Componentes del grupo

- ✓ Alina Gheorghita
- ✓ Cristina García
- ✓ Pilar Torralbo
- ✓ Tomás Restrepo
- ✓ Guillermo José Hernández
- ✓ Laura Reyero

Identificación de tokens

Clasificamos los tokens que reconocerá nuestro analizador según el tipo al que pertenezcan, de la siguiente manera:

Tipo de token	Codificación
EOF	(FIN, null)
LIT_CHARACTER	(LIT_CHARACTER, [caracteres])
LIT_CADENA	(LIT_CADENA, [índice tabla])
CADENA	(CADENA, [puntero a tabla])
NUM_REAL	(NUM_REAL, [valor real])
NUM_ENTERO	(NUM_ENTERO, [valor entero])
SEPARADOR	(SEPARADOR, [enumerado asociado])
OP_ARITMETICO	(OP_ARITMETICO, [enumerado asociado])
OP_COMPARACION	(OP_COMPARACION, [enumerado asociado])
OP_LOGICO	(OP_LOGICO, [enumerado asociado])
OP_ASIGNACION	(OP_ASIGNACION, [enumerado asociado])

LIT_CHARACTER: secuencia de caracteres que empieza y acaba por comillas simples

LIT_CADENA: secuencia de caracteres que empieza y acaba por comillas dobles

CADENA: secuencia de caracteres que determinará los identificadores y palabras reservadas del analizador.

NUM_REAL: número real.

NUM_ENTERO: número entero.

SEPARADOR: enumerado "." | ";" | "{" | "}" | "[" | "]" | "#" | "##" | "(" | ")" | "<:" | ":>" | "<%" | "%>" | "%:" | "%:%"

OP_ARITMETICO: enumerado "+" | "-" | "++" | "--" | "*" | "/" | "%"

OP_COMPARACION: enumerado "==" | "!=" | "<" | ">" | "<=" | ">="

OP_LOGICO: enumerado "&&" | "||" | "!" | "&" | "|" | "~" | "^" | "<<" | ">>" | "and" | "and_eq" | "bitand" | "bitor" | "compl" | "not" | "not_eq" | "or" | "or_eq" | "xor" | "xor_eq"

OP_ASIGNACIÓN: enumerado "=" | "+=" | "-=" | "*=" | "/=" | "%=" | "^=" | "&=" | "|=" | ">>=" | "<<=" | "->"

Gramática del analizador léxico

Notación “habitual”

literal \rightarrow numero | cadCar | litBooleano | litString | litPuntero

litPuntero \rightarrow nullptr

litString \rightarrow “((CajonDesastre - {“, \, \n}) | secEscape | nombredacaracteruniversal})* ”

litBooleano \rightarrow true | false

cadCar \rightarrow ‘ (CajonDesastre - {‘, \, \n, secEscape, nombredacaracteruniversal})* ’

nombredacaracteruniversal \rightarrow \u cuartetoHex | \U cuartetoHex cuartetoHex

cuartetoHex \rightarrow digHex digHex digHex digHex

secEscape \rightarrow secSimpleEsc | secOctalEsc | secHexEsc

secSimpleEsc \rightarrow \, ‘ | * | ? | \ | a | b | f | n | r | t | v

secOctalEsc \rightarrow \, octal | octal octal | octal octal octal

secHexEsc \rightarrow \x digHex+

numero \rightarrow entero | real

entero \rightarrow (decimal | hexadecimal | octal), [sufEntero]

hexadecimal \rightarrow 0x | 0X, digitoHex+

octal \rightarrow 0, digOct

decimal \rightarrow digito | digSinCero digito* [exponente]

sufEntero \rightarrow (sufSinSigno [sufijoLargo]) | (sufSinSigno [sufijoLargoLargo]) |
(sufLargo [sufijoSinSigno]) | (sufLargoLargo [sufijoSinSigno])

sufijoSinSigno \rightarrow u | U

sufijoLargo \rightarrow l | L

sufijoLargoLargo \rightarrow ll | LL

real \rightarrow . digito+ [exponente] [sufReal] | digito+ . digito* [exponente] [sufReal] |
digito+ exponente [sufReal]

exponente \rightarrow e | E, [+ | -], digito+

sufReal \rightarrow f | l | F | L

identificador \rightarrow noDigito (noDigito | digito)*

digOct \rightarrow 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7

digHex \rightarrow digito | A | B | C | D | E | F | a | b | c | d | e | f

noDigito \rightarrow “_” | letra

cajonDesastre \rightarrow letra | digito | “_” | “{” | “}” | “[” | “]” | “#” | “(” | “)” | “<” | “>” | “%” | “.” | “;” | “.” | “?” | “*” | “+” | “-” | “/” | “^” | “&” | “|” | “” | “!” | “=” | “,” | “\” | “” | “”

letra \rightarrow "A" | "B" | "C" | "D" | "E" | "F" | "G" | "H" | "I" | "J" | "K" | "L" | "M" | "N" | "O" | "P" | "Q" | "R" | "S" | "T" | "U" | "V" | "W" | "X" | "Y" | "Z" | "a" | "b" | "c" | "d" | "e" | "f" | "g" | "h" | "i" | "j" | "k" | "l" | "m" | "n" | "o" | "p" | "q" | "r" | "s" | "t" | "u" | "v" | "w" | "x" | "y" | "z"

digito \rightarrow digSinCero | 0

digSinCero \rightarrow 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9

DELIM \rightarrow ‘ ’ (blanco) | TAB | EOL | EOF | ‘;’ | ‘|’ | ‘:’ | ‘+’ | ‘-’ | ‘/’ | ‘*’ | ‘<’ | ‘>’ | ‘=’ | ‘&’ | ‘^’ | ‘%’ | ‘!’ | ‘~’ | ‘{’ | ‘}’ | ‘[’ | ‘]’ | ‘#’ | ‘(’ | ‘)’

DELIM2 \rightarrow DELIM | digito | noDigito

Notación EBNF

literal = numero | cadCar | litBooleano | litString | litPuntero ;

litPuntero = nullptr ;

litString = ‘ ‘ ‘ , (cajonDesastre2 | secEscape | nombredacaracteruniversal),
{ (cajonDesastre2 | secEscape | nombredacaracteruniversal}, ‘ ‘ ‘ ;

litBooleano = true | false ;

cadCar = “ ” , (CajonDesastre - {“ ” , “\”, “\n”, secSalida, nombredacaracteruniversal}),
{CajonDesastre - {‘\’,\n,secEscape,nombredacaracteruniversal}}, “ ” ;

nombredacaracteruniversal = ‘u’, cuartetoHex | ‘U’, cuartetoHex, cuartetoHex ;

cuartetoHex = digHex, digHex, digHex, digHex ;

secEscape = simpleSeq | octalSeq | hexSeq ;

secSimpleEsc = \ , ‘ | * | ? | \ | a | b | f | n | r | t | v ;

```

secOctalEsc = \ , octal | (octal, octal) | (octal, octal, octal) ;

secHexEsc = '\x', digHex, {digHex} ;

numero = entero | real ;

entero = (decimal | hexadecimal | octal), [sufEntero] ;

hexadecimal = '0x' | '0X', digHex, {digHex} ;

octal = 0, 0 | 1 | 2 | 3 | 4 | 5 | 6 | 7 ;

decimal = digito | digSinCero, {digito}, [exponente] ;

sufEntero = (sufSinSigno [sufijoLargo]) | (sufSinSigno [sufijoLargoLargo]) |
(sufLargo [sufijoSinSigno]) | (sufLargoLargo [sufijoSinSigno]) ;

sufSinSigno = "u" | "U" ;

sufLargo = "l" | "L" ;

sufLargoLargo = 'll' | 'LL' ;

real = ((".", digito, {digito}) | (digito, {digito}, ".", {digito}), [exponente])
| (digito, {digito}, exponente), [sufReal] ;

exponente = e | E, [+ | -], digito, {digito} ;

sufReal = "F" | "f" | "F" | "L" ;

identificador = noDigito, (noDigito | digito)* ;

digHex = digito | A | B | C | D | E | F | a | b | c | d | e | f ;

noDigito = "_" | letra ;

cajonDesastre = letra | digito | "_" | "{" | "}" | "[" | "]" | "#" | "(" | ")" | "<" | ">" | "%" | ":" |
";" | "." | "?" | "*" | "+" | "-" | "/" | "^" | "&" | "|" | "" | "!" | "=" | "," | "\" | "'" | "''" ;

cajonDesastre2 = letra | digito | "_" | "{" | "}" | "[" | "]" | "#" | "(" | ")" | "<" | ">" | "%" | ":" |
";" | "." | "?" | "*" | "+" | "-" | "/" | "^" | "&" | "|" | "" | "!" | "=" | "," | "\" ;

letra = "A" | "B" | "C" | "D" | "E" | "F" | "G" | "H" | "I" | "J" | "K" | "L" | "M" | "N" | "O" | "P"
| "Q" | "R" | "S" | "T" | "U" | "V" | "W" | "X" | "Y" | "Z" | "a" | "b" | "c" | "d" | "e" | "f" | "g"
| "h" | "i" | "j" | "k" | "l" | "m" | "n" | "o" | "p" | "q" | "r" | "s" | "t" | "u" | "v" | "w" | "x" |
"y" | "z" ;

digito = digSinCero | 0 ;

digSinCero = 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 ;

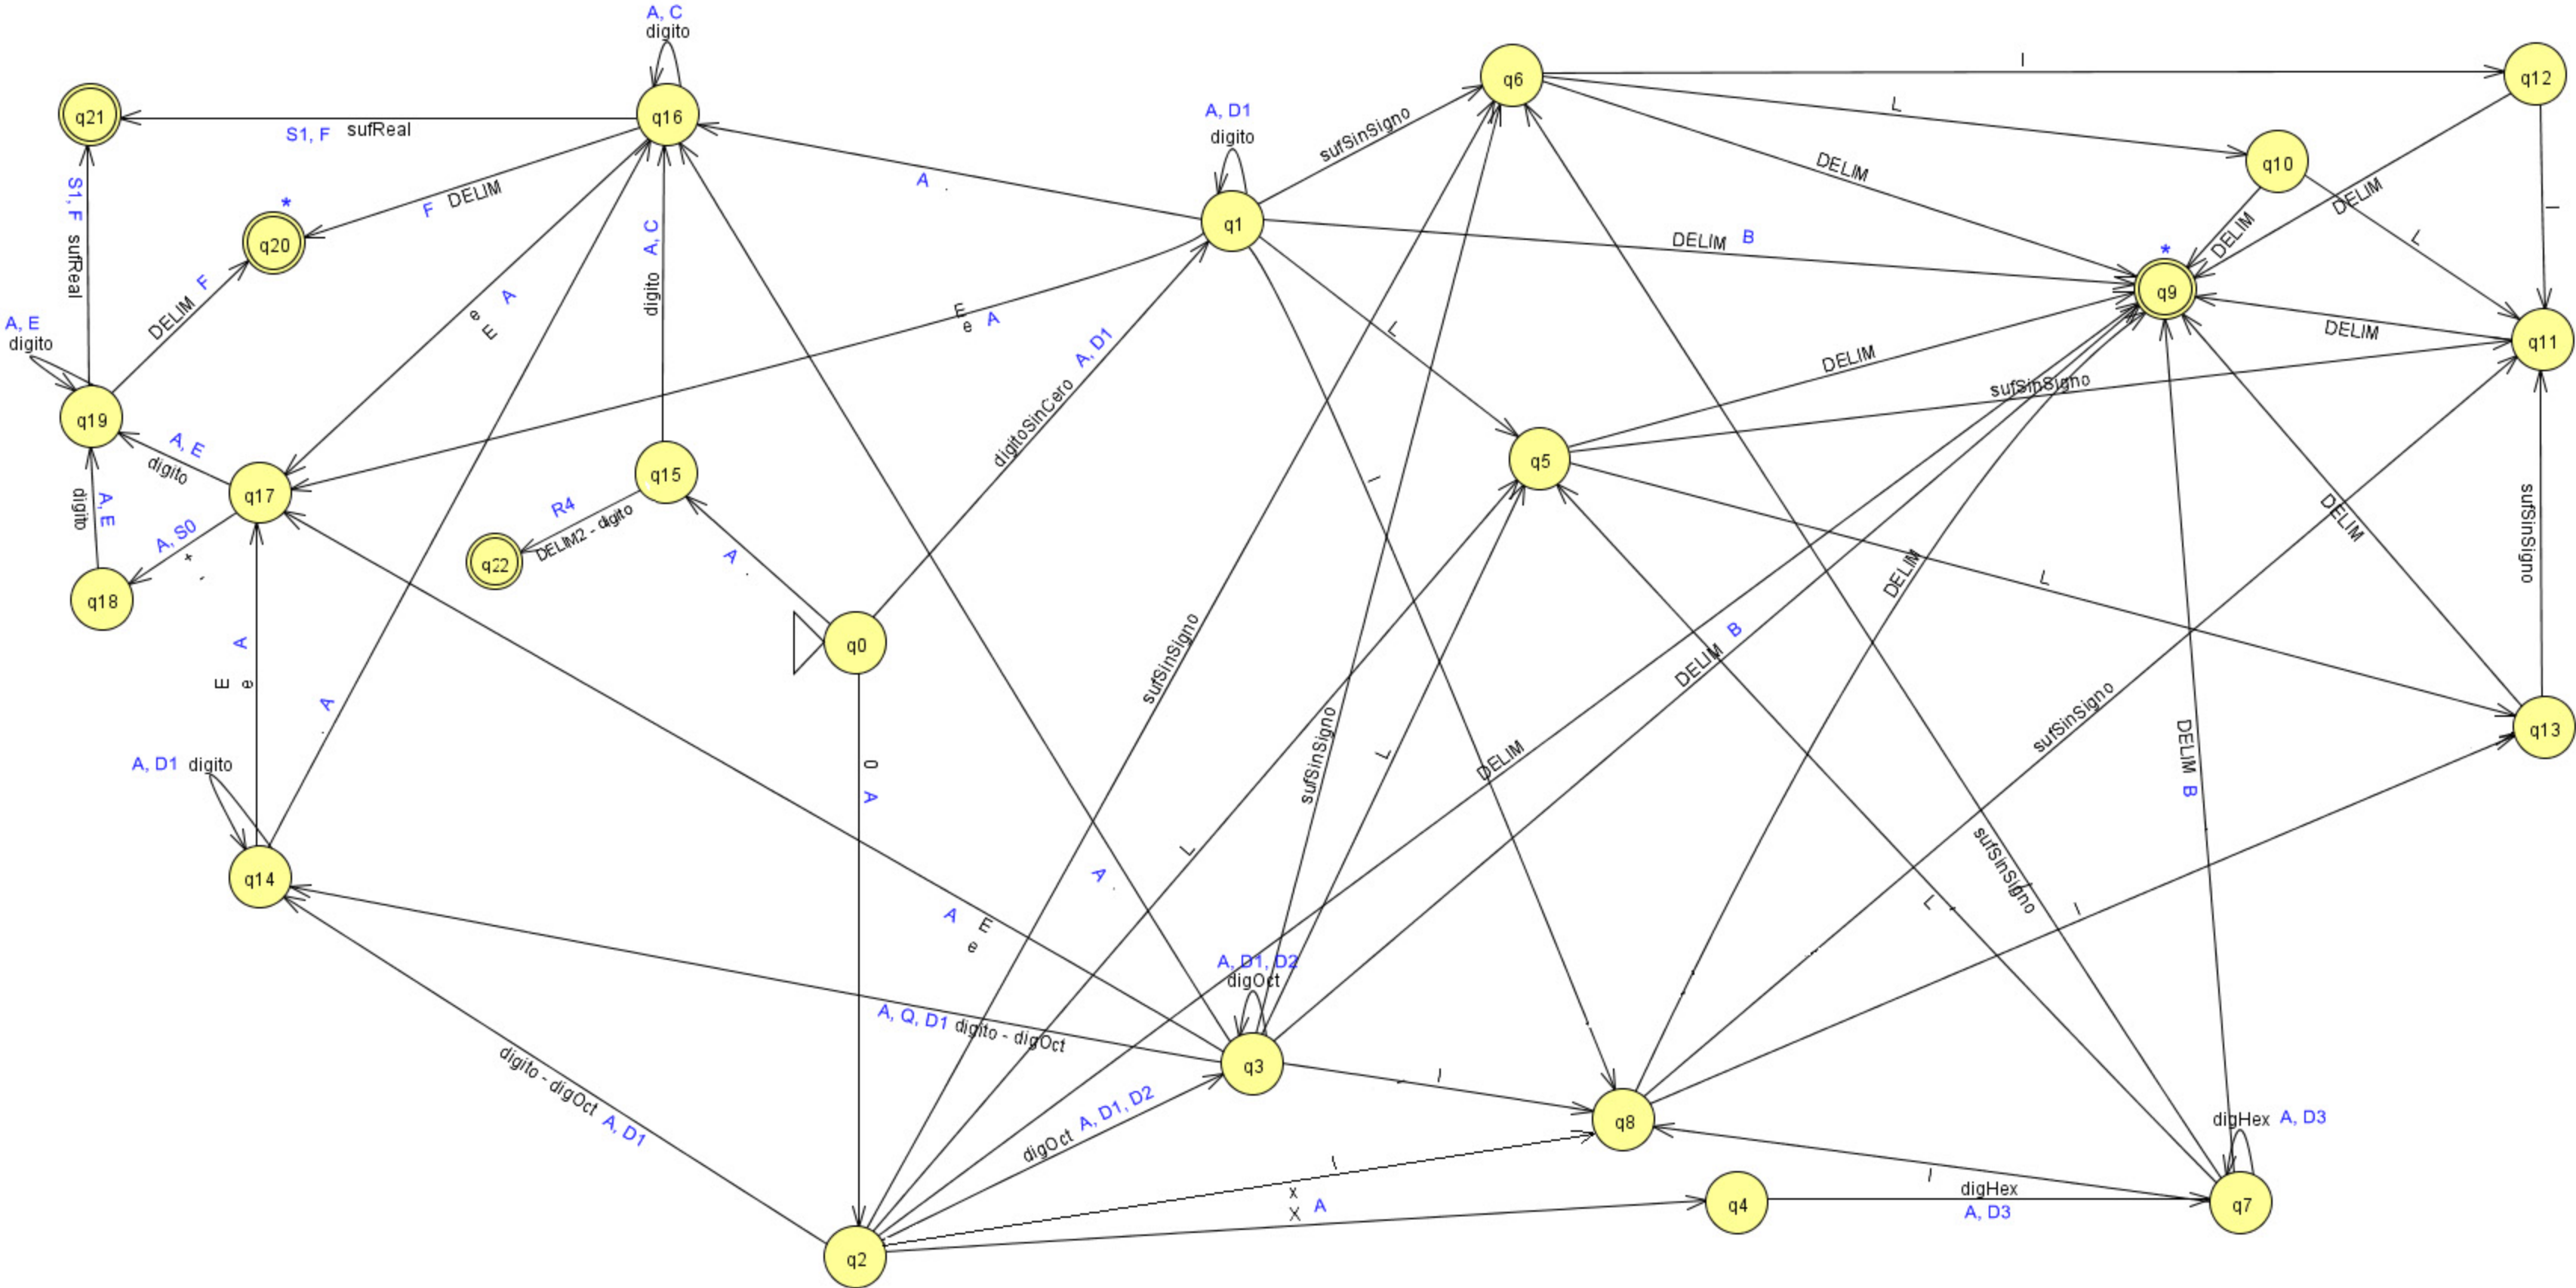
```

DELIM = ' ' (blanco) | TAB | EOL | EOF | ';' | '|' | ':' | '+' | '-' | '/' | '*' | '<' | '>' | '=' | '&' | '^' |
'%' | '!' | '~' | '{' | '}' | '[' | ']' | '#' | '(' | ')'


DELIM2 = DELIM | digito | noDigito ;

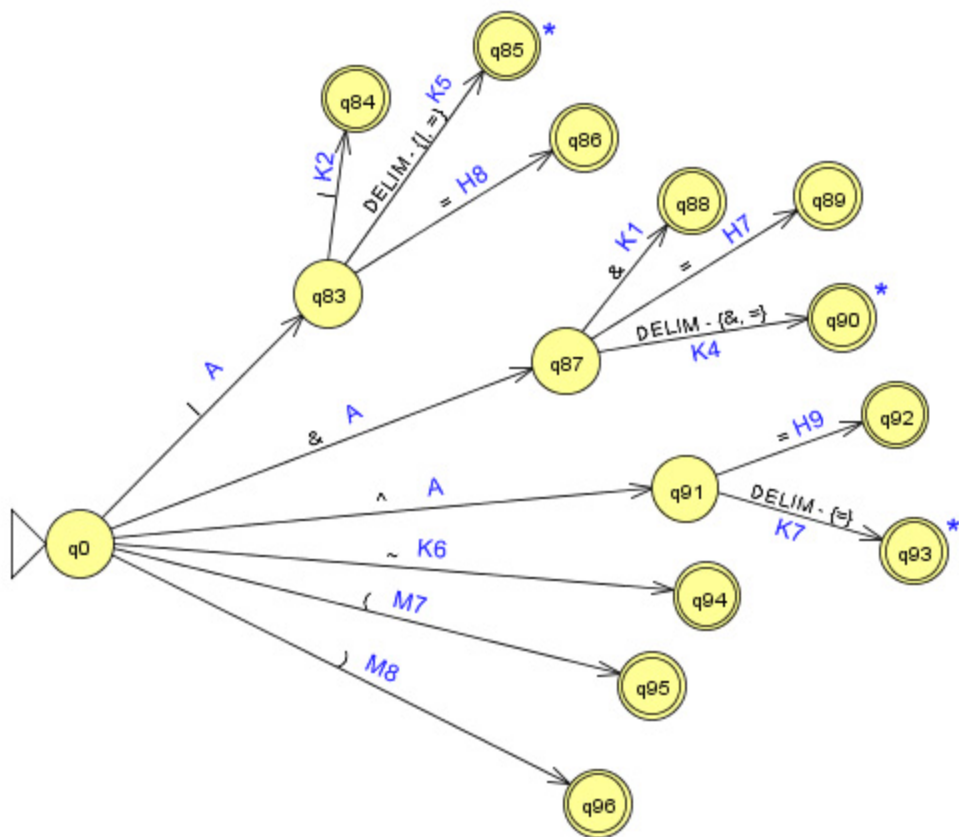
AUTÓMATA FINITO

NÚMEROS

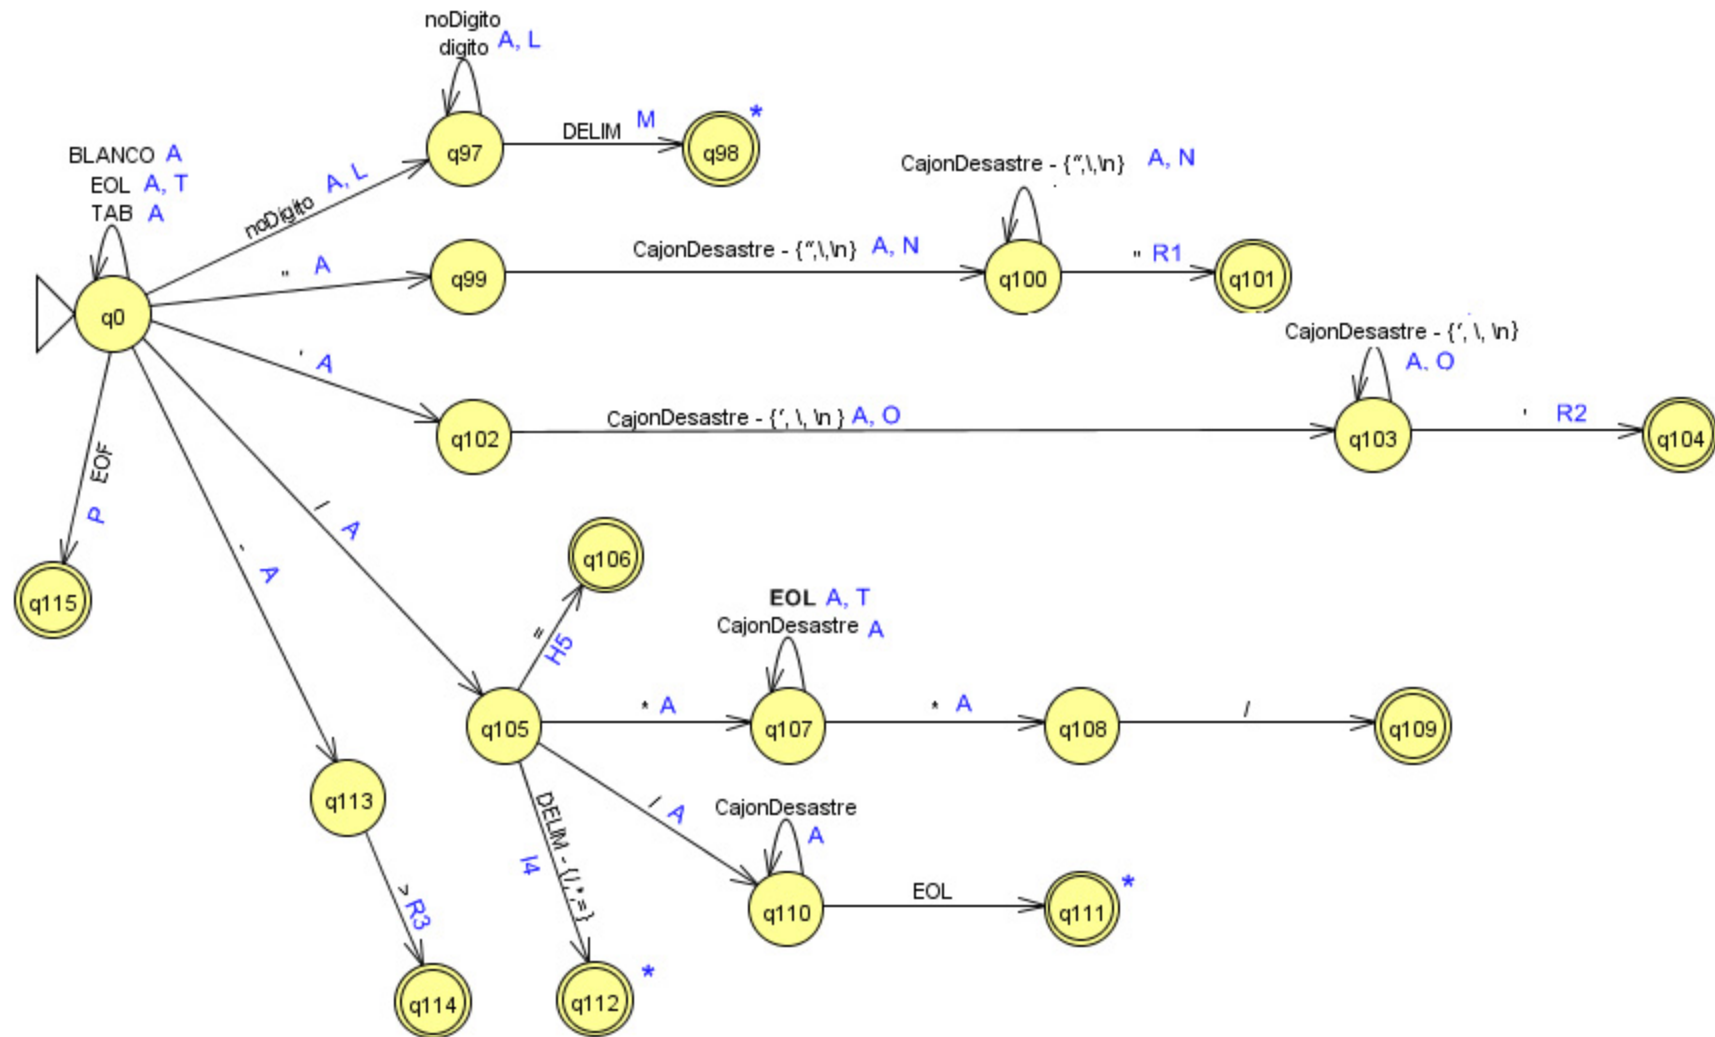


OPERADORES





RESTO DE TOKENS



Acciones semánticas

Reconocimiento de números

INIC: Código de inicialización de variables

A: Lee el siguiente carácter de la entrada (código fuente)

***** : Retrocede una posición el puntero de lectura del fichero fuente (devuelve el último carácter leído a la entrada)

B: Genera un token de número entero para el analizador sintáctico

C: Conversión y adición del carácter de preanálisis al valor acumulado de la parte decimal del número.

D1: Conversión y adición del carácter de preanálisis al valor acumulado de la parte entera del número. (base 10)

D2: Conversión y adición del carácter de preanálisis al valor acumulado de la parte entera del número. (base 8)

D3: Conversión y adición del carácter de preanálisis al valor acumulado de la parte entera del número. (base 16)

E: Conversión y adición del carácter de preanálisis al valor acumulado de la parte exponencial del número

S0: Guarda el signo de la E para los enteros (por ejemplo un 1 o un -1).

S1: Aplica un sufijo float a un número real.

S2: Aplica un sufijo entero a un número entero.

F: Genera un token de número real para el analizador sintáctico.

```
{  
token = GeneraToken(NUM_REAL, parteEntera + parteDecimal + parteExponencial * signo +  
sufijoReal);  
return token;  
}
```

G: Genera un token de número entero para el analizador sintáctico

```
{  
token = GeneraToken(NUM_ENTERO, parteEnteraDecimal + parteEnteraOctal +  
parteEnteraHexadecimal + sufijoEntero);  
return token;  
}
```


Reconocimiento de operadores

H1: Genera un token de operador de **asignación "="** para el analizador sintáctico.

```
{
token = GeneraToken (OP_ASIG, ASIG); //Valor del enumerado ASIG, si decidimos juntar los 3
tipos de operadores de asignacion en uno
return token;
}
```

H2: Genera un token de operador de **asignación con suma "+="** para el analizador sintáctico.

```
{
token = GeneraToken (OP_ASIG, ASIGSUM);
return token;
}
```

H3: Genera un token de operador de **asignación con resta "-="** para el analizador sintáctico.

H4: Genera un token de operador de **asignación con multiplicacion "*="** para el analizador sintáctico.

H5: Genera un token de operador de **asignación con division "/="** para el analizador sintáctico.

H6: Genera un token de operador de **asignación con modulo "%="** para el analizador sintáctico.

H7: Genera un token de operador de **asignación con and "&="** para el analizador sintáctico.

H8: Genera un token de operador de **asignación con or "|="** para el analizador sintáctico.

H9: Genera un token de operador de **asignación con xor "^="** para el analizador sintáctico.

H10: Genera un token de operador de **asignación ">>="** para el analizador sintáctico.

H11: Genera un token de operador de **asignacion "<<="** para el analizador sintáctico.

I1: Genera un token de operador **aritmético suma "+"** para el analizador sintáctico.

```
{
token = GeneraToken (OP_ARIT, SUMA); //Valor del enumerado SUMA
return token;
}
```

I2: Genera un token de operador **aritmético resta "-"** para el analizador sintáctico.

I3: Genera un token de operador **aritmético multiplicacion "*" para el analizador sintáctico.**

I4: Genera un token de operador **aritmético division "/" para el analizador sintáctico.**

I5: Genera un token de operador **aritmético modulo "%" para el analizador sintáctico.**

I6: Genera un token de operador **aritmético "++" para el analizador sintáctico.**

I7: Genera un token de operador **aritmético "--" para el analizador sintáctico.**

J1: Genera un token de operador **comparación igual "=="** para el analizador sintáctico.

```
{
token = GeneraToken (OP_COMP, IGUAL); //Valor del enumerado SUMA
return token;
}
```

J2: Genera un token de operador **comparación distinto "!="** para el analizador sintáctico.

J3: Genera un token de operador **comparación menor "<" para el analizador sintáctico.**

- J4:** Genera un token de operador **comparación mayor ">"** para el analizador sintáctico.
- J5:** Genera un token de operador **comparación menor igual "<="** para el analizador sintáctico.
- J6:** Genera un token de operador **comparación mayor igual ">="** para el analizador sintáctico.
-

- K1:** Genera un token de operador **lógico "&&"** para el analizador sintáctico.

```
{  
token = GeneraToken (OP_LOG, AND); //Valor del enumerado SUMA  
return token;  
}
```

- K2:** Genera un token de operador **lógico "||"** para el analizador sintáctico.
- K3:** Genera un token de operador **lógico "!"** para el analizador sintáctico.
- K4:** Genera un token de operador **lógico "&"** para el analizador sintáctico.
- K5:** Genera un token de operador **lógico "|"** para el analizador sintáctico.
- K6:** Genera un token de operador **lógico "~"** para el analizador sintáctico.
- K7:** Genera un token de operador **lógico "^"** para el analizador sintáctico.
- K8:** Genera un token de operador **lógico "<<"** para el analizador sintáctico.
- K9:** Genera un token de operador **lógico ">>"** para el analizador sintáctico.
-

- M1:** Genera un token separador **punto y coma ";"** para el analizador sintáctico.

```
{  
token = GeneraToken (SEP, PUNTCOMA);  
return token;  
}
```

- M2:** Genera un token separador **corchete abierto "["** para el analizador sintáctico.
- M3:** Genera un token separador **corchete cerrado "]"** para el analizador sintáctico.
- M4:** Genera un token separador **punto y coma ";"** para el analizador sintáctico.
- M5:** Genera un token separador **almohadilla "#"** para el analizador sintáctico.
- M6:** Genera un token separador **almohadilla doble "##"** para el analizador sintáctico.
- M7:** Genera un token separador **paréntesis abierto "("** para el analizador sintáctico.
- M8:** Genera un token separador **paréntesis cerrado ")"** para el analizador sintáctico.
- M9:** Genera un token separador **llave abierta "{"** para el analizador sintáctico.
- M10:** Genera un token separador **llave cerrada "}"** para el analizador sintáctico.

Reconocimiento del resto

- L:** Añade el carácter leído al final del lexema ya acumulado:
{ Concatena(lexema, preanalisis); }

- M:** Búsqueda del lexema en la tabla de palabras reservadas y si lo encuentra devuelve el token, si no lo encuentra búsqueda/inserción en la tabla de símbolos y generación del token para el analizador sintáctico:

```
{  
    token = TS.getPalRes.Busca(lexema);  
    if(token != null)  
        return token;  
token = TS.Busca(lexema);  
if (token == NULL) {
```

```

token = GeneraToken(ID, TS.Inserta(lexema));
return token;
    }
}

```

N: Añade el carácter leído al final de la cadena con comillas dobles ya acumulado:
{ Concatena(cadenaComDobles(litString), preanalisis); }

O: Añade el carácter leído al final de la lexema cadena con comillas simples ya
acumulado:
{ Concatena(cadenaComSimples(cadCar), preanalisis); }

P : Genera un token de fin de la entrada para el analizador sintáctico:
{
token = GeneraToken (FIN, NULL);
return token;
}

Q: Se queda con la parte calculada en base decimal

R1: Genera un token de tipo LIT_CADENA

R2: Genera un token de tipo LIT_CHARACTER

R3: Genera un token flecha (para punteros)

R4: Genera un token punto

T: Incrementa el número de líneas

[illegible]

													DELIM2													
		[]	{	}	()	#	~	+	-	:	/	*	^	<	>	%	=		;	!	&	digito	noDigito	
OPERANDS	q0	q73	q82	q74	q53	q95	q96	q60	q94	q41	q45	q81		q49	q91	q75	q68	q52	q64	q83	q40	q62	q87			
	q41									q43			q44	q44	q44	q44	q44	q44	q42	q44	q44	q44	q44	q44	q44	
	q45										q46		q47	q47	q47	q47	q47	q47	q48	q47	q47	q47	q47	q47	q47	
	q49												q50	q50	q50	q50	q50	q50	q51	q50	q50	q50	q50	q50	q50	
	q52											q56	q54	q54	q54	q54	q53	q54	q55	q54	q54	q54	q54	q54	q54	
	q56												q58	q58	q58	q58	q58	q57	q58	q58	q58	q58	q58	q58	q58	
	q57											q59														
	q60							q59					q58	q58	q58	q58	q58	q58	q58	q58	q58	q58	q58	q58	q58	
	q62												q63	q63	q63	q63	q63	q63	q62	q63	q63	q63	q63	q63	q63	
	q64												q66	q66	q66	q66	q66	q66	q65	q66	q66	q66	q66	q66	q66	
	q68												q67	q67	q67	q67	q69	q67	q70	q67	q67	q67	q67	q67	q67	
	q69												q72	q72	q72	q72	q72	q72	q71	q72	q72	q72	q72	q72	q72	
	q75											q73	q77	q77	q77	q78	q77	q74	q76	q77	q77	q77	q77	q77	q77	
	q78												q80	q80	q80	q80	q80	q80	q79	q80	q80	q80	q80	q80	q80	
	q81																q82									
	q83													q85	q85	q85	q85	q85	q85	q86	q84	q85	q85	q85	q85	q85
	q87													q90	q90	q90	q90	q90	q90	q89	q90	q90	q90	q88	q90	q90
	q91													q93	q93	q93	q93	q93	q93	q92	q93	q93	q93	q93	q93	q93

[illegible]

Tabla de símbolos

Para C++ los ámbitos se definen al abrir llave ({) y cerrar llave (}) y en cualquier zona que se comporte como ámbito, se podrán declarar variables (bucles for, while, registros, case...).

Como decidimos implementar la práctica en Java, podemos usar sus objetos predefinidos, como hash tables, hash map, enum map, listas dinámicas, etc para la gestión de la tabla de símbolos.

Gestión de palabras reservadas.

Dado que las palabras clave son también palabras reservadas, se van a almacenar dentro de la tabla de símbolos al arrancar el compilador.

Vamos a tener una tabla de palabras reservadas donde el campo clave es la cadena de caracteres que identifica a la palabra reservada. Como campo valor almacenaremos un valor numérico que identifique a cada una de las palabras.

Gestión de ámbitos.

Vamos a gestionar nuestra tabla de símbolos con una tabla separada para cada ámbito. Tendremos una tabla de símbolos global, en la que almacenaremos cada identificador encontrado en ese ámbito junto con su tipo, así como una entrada para cada nuevo ámbito que aparezca en el código. Esta entrada tendrá información sobre el número de argumentos y su tipo, la forma de pasar los argumentos, el tipo de retorno y un puntero a la propia tabla de ese ámbito donde estará almacenada la información que él contiene.

En cada una de las tablas asociadas a los ámbitos, aparecerá como último atributo, un puntero que señalará cual es su ámbito padre.

Tendremos un puntero BLOQUE_ACTUAL para facilitar la búsqueda dentro de la tabla de símbolos, y que como su propio nombre indica, apuntará al bloque actual.

Gestión de los errores

Funcionamiento básico

- ✓ Sustituirá a la gestión de errores básica en cualquier generador léxico-sintáctico como Javacc.
- ✓ Debe contabilizar el número de errores Léxicos y el número de errores sintácticos.
- ✓ Ofrecerá métodos distintos para insertar errores léxicos y sintácticos.
- ✓ Un método para imprimir los errores finales.
- ✓ Dos tablas distintas para léxico y sintáctico, cada una con la tabla de errores creada por las distintas transiciones incorrectas, mas errores gramaticales distintos en el sintáctico.
- ✓ Informativo, no soluciona errores.

Tipos

Dos tipos distintos:

- ✓ Error Léxico
- ✓ Error Sintáctico

Principalmente se distinguen en que acceden a dos tablas distintas de errores y que el léxico guarda el carácter que produce el error, mientras que el sintáctico da línea y tipo de error (mucho mejor distinguidos).

Interfaz

- ✓ **void insertarErrorLex:** Requiere el carácter que ha dado el error, número de línea, número de error. Inserta en una lista un error de tipo Léxico.
- ✓ **void insertaErrorSin:** Inserta en una lista un error de tipo sintáctico.
- ✓ **int imprimeErrores:**
 - Devuelve un integer: 0 si no han ocurrido errores hasta el momento, 1 en otro caso.
 - Imprime los errores ocurridos de la forma:
“No hubo errores léxicos”
“5 errores léxicos:
 “Línea 5. Llego un * se esperaba (lista de valores válidos según el error de la tabla)
 Línea 6...”

La impresión de errores sintácticos incluso mensajes de error más variados: Identificador no declarado, errores de tipos etc.

Tabla de errores léxicos

Asigna distintos String que describen errores léxicos a números de entrada

TABLA DE ERRORES	
I	Carácter inesperado
II	Se esperaba el simbolo ':'
III	Se esperaba el simbolo '>'
IV	Se esperaba el simbolo '/'
V	Numero mal formado
VI	Se esperaba numero en formato Hexadecimal